

Отчет по ETL, Петров Александр, инженерия данных.

1.База данных MongoDB.

В данной работе с помощью скрипта generate_mongo_data.py создана и заполнена база данных интернет магазина ecommerce .

База содержит следующие коллекции:

Коллекция **users**

Хранит информацию о пользователях интернет-магазина.

Поле	Тип	Описание
user_id	Integer	Уникальный идентификатор пользователя (первичный ключ)
name	String	ФИО пользователя (сгенерировано Faker)
email	String	Email (5% записей имеют пустое значение для тестирования фильтрации)
city	String	Город проживания
registration_date	Date	Дата регистрации (за последние 2 года)

Количество документов: 150

Коллекция **products**

Содержит товарный справочник.

Поле	Тип	Описание
product_id	Integer	Уникальный идентификатор товара
name	String	Название товара (фиксированный список реальных наименований)
category	String	Категория: Электроника, Одежда, Книги, Дом и сад, Спорт, Игрушки, Косметика
price	Float	Цена в рублях (разная для каждой категории)

Количество документов: 40

Коллекция **orders**

Хранит заказы пользователей.

Поле	Тип	Описание
order_id	Integer	Исходный идентификатор заказа (в MongoDB)
user_id	Integer	Ссылка на пользователя
order_date	Date	Дата заказа
status	String	Статус: completed (80%) или cancelled (20%)
items	Array	Массив товаров в заказе
↳ product_id	Integer	Идентификатор товара
↳ quantity	Integer	Количество единиц товара

Количество документов: 800

Коллекция `reviews`

Содержит отзывы пользователей на товары.

Поле	Тип	Описание
<code>review_id</code>	Integer	Уникальный идентификатор отзыва
<code>product_id</code>	Integer	Ссылка на товар
<code>user_id</code>	Integer	Ссылка на пользователя
<code>rating</code>	Integer	Оценка от 1 до 5
<code>comment</code>	String	Текст отзыва (необязательный)
<code>created_date</code>	Date	Дата написания отзыва

Количество документов: ~250

Пример объектов базы ecommerce, коллекция `orders`:

```
ecommerce> db.orders.find({ status: { $ne: "completed" } }).limit(5).pretty()
[
  {
    _id: ObjectId('69c6ba860d1752e10d920ea2'),
    order_id: 12,
    user_id: 36,
    order_date: '2025-07-25',
    status: 'cancelled',
    items: [
      { product_id: 5, quantity: 1 },
      { product_id: 24, quantity: 2 },
      { product_id: 11, quantity: 2 }
    ]
  },
  {
    _id: ObjectId('69c6ba860d1752e10d920ea8'),
    order_id: 18,
    user_id: 117,
    order_date: '2025-10-12',
    status: 'cancelled',
    items: [ { product_id: 3, quantity: 2 }, { product_id: 24, quantity: 1 } ]
  },
  {
    _id: ObjectId('69c6ba860d1752e10d920ea9'),
    order_id: 19,
    user_id: 57,
    order_date: '2024-09-08',
    status: 'cancelled',
    items: [ { product_id: 7, quantity: 2 }, { product_id: 36, quantity: 2 } ]
  },
]
```

2. Загрузка данных в базу PostgreSQL.

Загрузка данных из ecommerce в PostgreSQL реализована с помощью Dag final_etl.py. Сначала скрипт создает целевые таблицы в базе airflow PostgreSQL или очищает их, если они уже существуют. Реализована полная перезакачка данных.

Все объекты, кроме orders раскладываются в линейную структуру напрямую каждый в свою целевую таблицу. Orders раскладывается в 2 целевые таблицы - fact_orders (хранит связь id пользователя и его заказа) и fact_order_items (хранит связь id заказа с id товара и количества данного товара в заказе).

Вот объекты базы airflow:

```
CREATE TABLE IF NOT EXISTS dim_users (  
    user_id INTEGER PRIMARY KEY,  
    name VARCHAR(100),  
    email VARCHAR(100),  
    city VARCHAR(50),  
    registration_date DATE  
);
```

```
CREATE TABLE IF NOT EXISTS dim_products (  
    product_id INTEGER PRIMARY KEY,  
    name VARCHAR(200),  
    category VARCHAR(50),  
    price NUMERIC  
);
```

```
CREATE TABLE IF NOT EXISTS fact_orders (  
    order_id INTEGER PRIMARY KEY,  
    user_id INTEGER,  
    order_date DATE,  
    status VARCHAR(20)  
);
```

```
CREATE TABLE IF NOT EXISTS fact_order_items (  
    order_id INTEGER,  
    product_id INTEGER,  
    quantity INTEGER,  
    PRIMARY KEY (order_id, product_id)  
);
```

```
CREATE TABLE IF NOT EXISTS fact_reviews (  
    review_id INTEGER PRIMARY KEY,  
    product_id INTEGER,  
    user_id INTEGER,  
    rating INTEGER,  
    comment TEXT,
```

created_date DATE

Для целевой таблицы **dim_users** исключаются строки, для которых:

- email пустой или null

Для целевой таблицы **fact_orders** исключаются строки, для которых:

- статус заказа status <> 'completed'
- дублируется order_id, для одинаковых order_id оставляем последнюю запись, те с максимальным order_date
- записи сортируются по order_date

Запрос к объектам базы данных airflow после работы пайплайна:

```
SELECT 'dim_users' as table_name, COUNT(*) FROM dim_users
UNION ALL SELECT 'dim_products', COUNT(*) FROM dim_products
UNION ALL SELECT 'fact_orders', COUNT(*) FROM fact_orders
UNION ALL SELECT 'fact_order_items', COUNT(*) FROM fact_order_items
UNION ALL SELECT 'fact_reviews', COUNT(*) FROM fact_reviews;
```

результат 1 ✕

SELECT 'dim_users' as table_name, COUNT(*) FROM dim_users UNION / Введите SQL выражение чтобы с

	A-Z table_name	123 count
1	dim_users	144
2	dim_products	40
3	fact_orders	649
4	fact_order_items	1 840
5	fact_reviews	420

3. Создание аналитических витрин.

Реализовано 2 витрины данных в виде таблиц базы airflow: top_products_last_month и top_users_last_month. Обе витрины заполняются с помощью dag create_vitrines.py.

3.1 Витрина статистики 10 самых популярных товаров в текущем месяце (или последнем месяце, по которому есть записи).

Структура таблицы:

Поле	Тип	Описание
product_id	INTEGER	ID товара
product_name	VARCHAR	Название товара
category	VARCHAR	Категория
avg_rating	NUMERIC	Средний рейтинг (за всё время)
last_month_sales	INTEGER	Количество продаж за последний месяц
last_month_revenue	NUMERIC	Выручка за последний месяц
total_sales_all_time	INTEGER	Общее количество продаж за всё время
total_revenue_all_time	NUMERIC	Общая выручка за всё время

Данные витрины, после выполнения пайплайна:

```
select * from top_products_last_month
```

product_id	product_name	category	avg_rating	last_month_sales	last_month_revenue	total_sales_all_time	total_revenue_all_time
7	Колонка Smart	Электроника	3,5	6	272 829,24	85	3 865 080,9
16	Пальто осеннее	Одежда	3,25	6	38 157,18	100	635 953
28	Набор кастрюль	Дом и сад	3	6	10 450,74	97	168 953,63
20	Преступление и наказ	Книги	2,82	6	1 835,1	103	31 502,55
26	Сто лет одиночества	Книги	3	5	3 014,7	85	51 249,9
6	Телевизор 4К	Электроника	2,83	5	182 106,9	104	3 787 823,52
30	Ковер с узорами	Дом и сад	2,5	4	12 037,28	102	306 950,64
22	1984	Книги	3,67	4	3 713,32	84	77 979,72
39	Скакалка	Спорт	3,08	4	28 680,96	97	695 513,28
9	Дрон	Электроника	2,93	3	77 162,16	105	2 700 675,6

3.1 Витрина статистики 10 самых активных пользователей по числу купленных товаров в текущем месяце (или последнем месяце, по которому есть записи).

Поле	Тип	Описание
user_id	INTEGER	ID пользователя
user_name	VARCHAR	Имя пользователя
city	VARCHAR	Город
items_purchased_last_month	INTEGER	Количество купленных товаров за последний месяц
total_spent_last_month	NUMERIC	Сумма трат за последний месяц
orders_count_last_month	INTEGER	Количество заказов за последний месяц
reviews_last_month	INTEGER	Количество отзывов за последний месяц
avg_rating_last_month	NUMERIC	Средняя оценка в отзывах за последний месяц
total_reviews_all_time	INTEGER	Общее количество отзывов за всё время

Данные витрины, после выполнения пайплайна,
(селект через * плохо читается, поэтому добавил второй скрин, на котором не видны атрибутов в выводе, но явно перечислены в селекте) :

```
select * from top_users_last_month
```

user_id	user_name	city	items_purchased_last_month	total_spent_last_month	orders_count_last_month	reviews_last_month	avg_rating_last_month	total_reviews_all_time
150	Василиса Эльдаровна Мельникова	клх Самара	5	28 091,9	1	0	0	1
97	Капитон Игоревич Ефремов	к. Ялutorовск	5	34 335,12	1	4	2,5	11
81	Вячеслав Артёмович Семенов	с. Гремячинск (	5	32 299,5	1	3	4	4
143	Елисеев Савелий Юлианович	клх Вендинга	4	51 217,77	1	0	0	0
9	Анастасия Евгеньевна Бирюкова	г. Каспийск	4	32 272,5	1	0	0	4
24	Тарасов Изот Владленович	г. Забайкальск	4	167 650,08	1	1	1	3
41	Дарья Харитоновна Силина	клх Можайск	3	114 658,45	1	1	3	3
36	Алина Матвеевна Никитина	д. Елец	2	110 494,31	1	1	3	5
112	Белозеров Тимофей Венедиктович	д. Елец	2	9 437,46	1	2	3	2
118	Зайцев Владлен Федосеевич	с. Новый Оскол	2	2 462,89	1	0	0	2

```
select
  user_id,
  user_name,
  city,
  items_purchased_last_month,
  total_spent_last_month,
  orders_count_last_month,
  reviews_last_month,
  avg_rating_last_month,
  total_reviews_all_time
from top_users_last_month B
```

users_last_month 1 X									
user_id, user_name, city, items_purchased_last_month, total_spent_las Введите SQL выражение чтобы отфильтровать результаты									
123	user_id	A-Z	user_name	A-Z	city	123	123	total_	123
150	Василиса Эльдаровна Мельникова	клх	Самара	5	28 091,9	1	0	0	1
97	Капитон Игоревич Ефремов	к.	Ялуторовск	5	34 335,12	1	4	2,5	11
81	Вячеслав Артёмович Семенов	с.	Гремячинск (Бурят.)	5	32 299,5	1	3	4	4
143	Елисеев Савелий Юлианович	клх	Вендинга	4	51 217,77	1	0	0	0
9	Анастасия Евгеньевна Бирюкова	г.	Каспийск	4	32 272,5	1	0	0	4
24	Тарасов Изот Владленович	г.	Забайкальск	4	167 650,08	1	1	1	3
41	Дарья Харитоновна Силина	клх	Можайск	3	114 658,45	1	1	3	3
36	Алина Матвеевна Никитина	д.	Елец	2	110 494,31	1	1	3	5
112	Белозеров Тимофей Венедиктович	д.	Елец	2	9 437,46	1	2	3	2
118	Зайцев Владлен Федосеевич	с.	Новый Оскол	2	2 462,89	1	0	0	2

4.Скрин запуска пайплайнов в airflow.

localhost:8080/home

Airflow

DAGs

Cluster Activity

Datasets

Security

Browse

Admin

Docs

Triggered create_vitrines, it should start any moment now.

DAGs

All 57Active 2Paused 55

Running 0Failed 0

Filter DAGs by tag

Search DAGs

DAG	Owner	Runs	Schedule	Last Run	Next Run	Recent Tasks
create_vitrines analyticsvitrines	airflow	1	None	2026-03-27, 23:32:14		2
final_etl etlfinalmongodb	airflow	1	None	2026-03-27, 18:40:43		2

«

<

1

>

»